LevelDB TTL 与统计元数据

实验设计实现与验证报告

https://github.com/Daydream709/LevelDB_Project1

周光轩 唐一嘉

2026 年 11 月 5 日

摘要 本实验在 LevelDB 中实现带有效期的数据写入与当前物理记录统计，使两项功能在批量写入、快照、迭代器、恢复及 Compaction 中保持一致。TTL 保存绝对微秒截止时间，读取时过滤过期版本，回收时保护活跃读取视图；统计随成功安装的主数据状态发布。当前实现包含底层文件顺序回收、有界统计差分缓冲、SST 逐键局部计数索引，以及精确统计重建遇到损坏时的受限只读分支。后续审查仍发现畸形 WAL 批次的部分恢复风险和宽截止时间分布下的自动回收低估。局部计数索引阶段的基线与候选均有 280/280 次官方场景通过记录；性能收益依赖版本密度和缓存状态，联合 GC 的两个配置在交替复测中仍下降约 8.5% 和 7.5%。

1 项目目标与需求分析

1.1 实验任务

我们在同一份 LevelDB 源码中完成 TTL 和统计元数据功能。TTL 解决记录何时失效、何时可以回收的问题；统计接口描述数据库当前保存的内部记录规模。两者共用写入、版本管理与合并流程，因此需要统一设计提交边界，而不能只分别实现两个接口。

普通 Put 保持永久有效；带 TTL 的 Put 接收秒数并保存绝对截止时间。到期后 Get 返回 NotFound，迭代器跳过记录。快照还需固定读时间，避免同一快照随真实时间推移改变结果。本文到期语义以配置的 Env 时间为准；系统时钟回拨时，尚未物理删除的值可能重新满足未到期条件，当前实现没有额外的单调到期保证。

1.2 统计口径

GetCurrentStats 返回 total_entries、distinct_keys 和 seq。total_entries 统计 MemTable、Immutable MemTable 和当前 Version 中 SST 的内部记录；同一键的多个版本及删除标记分别计数。distinct_keys 按用户键原始字节去重，seq 表示对应状态的最新已发布序列号。

过期只改变读取可见性，不立即减少物理统计。只有内部记录实际回收并成功安装新 Version 后，统计值才减少。WAL 是恢复副本，不重复计入。统计查询忽略 ReadOptions::snapshot，始终返回当前状态。

这里的“物理记录”限定于当前发布状态，并非磁盘上所有尚未删除的 SST；仅被旧迭代器引用的历史 Version 文件不再重复计数。删除不存在的键也会新增删除标记，因此可使记录数与去重键数同时增加。若自定义比较器将 A 与 a 判等，两种原始字节仍分别计入 distinct_keys；这与 Get 的比较器等价语义不同。

1.3 设计约束

本实验保留 LevelDB 的 LSM 存储路径。扩展必须兼容普通写入、删除、WriteBatch、自定义比较器与恢复流程，并对零 TTL、时间溢出、快照保护以及 I/O 失败给出确定语义。

表 1 主数据操作与统计发布的伪代码

行号	伪代码
1	**if** 操作为用户写入 **then**
2	校验批次并准备统计增量
3	追加 WAL；按需执行 Sync
4	成功后插入 MemTable
5	持锁发布计数与最新序列号
6	**else if** 操作为刷盘 **then**
7	构建并同步 SST，安装新 Version
8	保持全局记录数不变
9	**else if** 操作为合并回收 **then**
10	构建输出并核对统计差分
11	安装文件变更与计数检查点
12	仅在安装成功后发布新统计

注：按操作类型分支，刷盘与合并不必紧随每次写入。此处省略队列与锁的细节；任一步失败即进入对应错误路径，不发布该操作的成功统计。

逻辑上，写入先生成可恢复记录，再更新可见状态；合并先准备新文件，再切换当前版本。统计在这些成功提交的边界更新，从而与数据状态对应。表 1 给出按操作类型划分的伪代码，具体路径中的并发协调见第 3 节。

报告以远程仓库 Daydream709/LevelDB_Project1 的当前实现为依据，说明 TTL 回收、恢复和 SST 局部计数索引，并列出已知边界。实验结果保留各自的对照设置与执行批次，不能代替在当前环境中的完整复测。

2 TTL 功能设计与实现

图 1 将截止时间编码、固定读取视图和安全回收串联起来。写入与回收共用主数据路径，读可见性与物理删除分别判断。

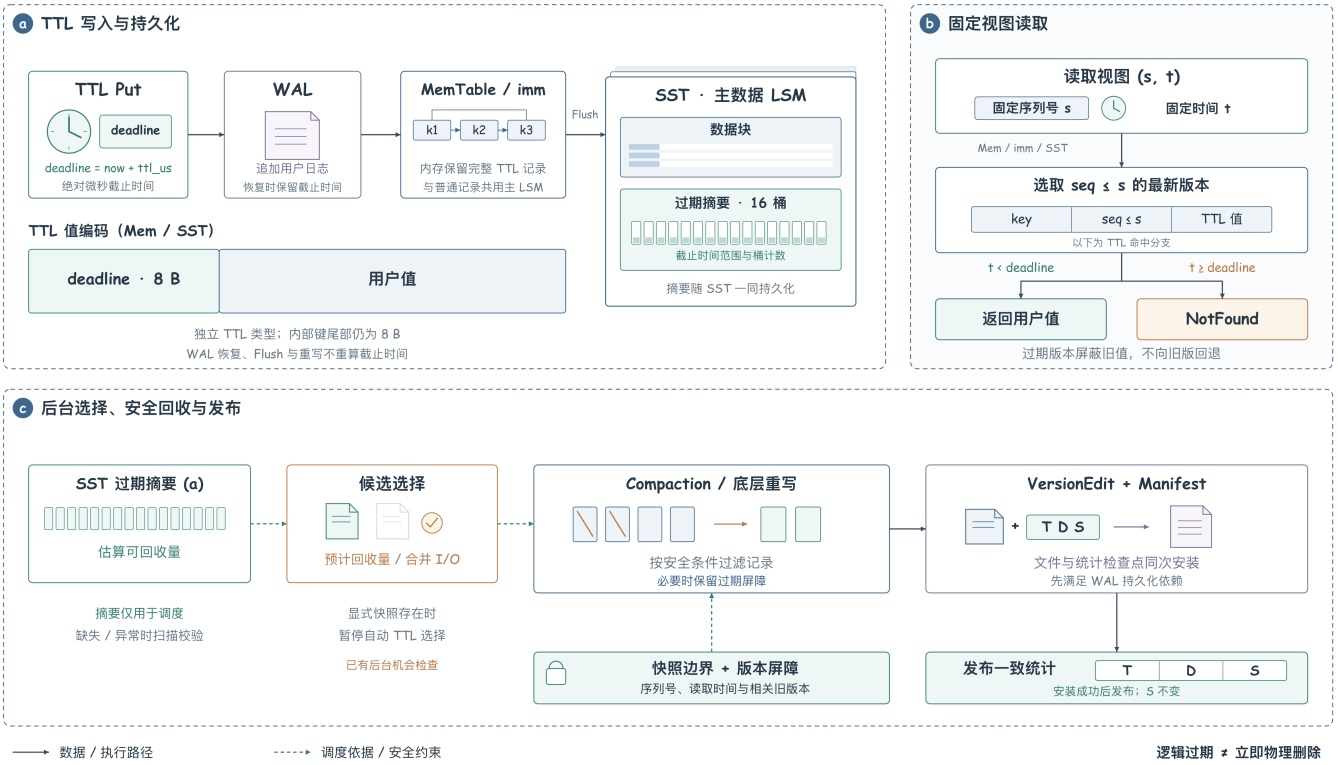


图 1　TTL 写入、固定视图读取与安全回收总览。(a) 截止时间沿主数据路径持久化；(b) 固定视图中的过期版本屏蔽旧值；(c) 摘要用于候选调度，删除受快照和版本规则约束，文件变更与统计同次提交。读取图省略损坏载荷的错误分支；后台选择不保证按时回收。

2.1 编码方案与接口

带 TTL 的 Put 通过 Options::env->NowMicros() 取得当前时间，将秒数转换为微秒，计算 deadline = now + ttl × 1,000,000。实现分别检查乘法和加法溢出，错误时返回 InvalidArgument，在进入写入提交前终止，不消耗用户序列号。截止时间在进入写队列前计算，排队与 I/O 时间也计入有效期，并非写入返回成功后才开始倒计时。

ttl=0 会写入立即过期的新版本，并正常消耗序列号。它不能等同于“永久有效”，也不能直接忽略写入，否则旧值可能继续可见。永久有效的数据仍通过普通 Put 写入。

表 2　TTL 在不同存储层的表示

位置	编码与职责
WriteBatch / WAL	类型标记、用户键、fixed64 截止时间、用户值
InternalKey	用户键、序列号与 kTypeValueWithTTL 类型
MemTable / SST value	8 字节绝对截止时间前缀，随后为用户值
普通记录	保留原有 value 类型与编码

WriteBatch::PutWithExpiration 接收绝对微秒截止时间，允许 TTL 写入与普通写入、删除放在同一原子批次。批次复制、提交和日志重放均保留原截止时间，避免恢复时重新计时。公开 Write 在入队前先校验完整批次，截断的 TTL 编码或错误操作数会返回 Corruption，不能先提交合法前缀。InternalKey 新增类型值 2，并将查找类型上界同步为该值；普通记录编码保持原样，不意味着旧版 LevelDB 能识别新增 TTL 类型。

表 3　TTL 截止时间的溢出检查

行号　执行语句

```
1  const uint64_t now = env_->NowMicros();
2  const uint64_t scale = 1000000;
3  if (ttl > std::numeric_limits<uint64_t>::max()
4          / scale)
5    return Status::InvalidArgument(
6        "TTL seconds overflow microseconds");
7  const uint64_t ttl_micros = ttl * scale;
8  if (now > std::numeric_limits<uint64_t>::max()
9          - ttl_micros)
10   return Status::InvalidArgument(
11       "TTL deadline overflows Env time");
12 deadline = now + ttl_micros;
```

注： 摘自 db/db_impl.cc 的 TTL Put 路径；仅调整换行，省略外层性能计时包装。先检查秒转微秒与时间加法，失败时不进入写入提交。

表 3 展示截止时间计算前的两级溢出检查。

2.2 读取与旧版本屏蔽

Get 先按读取序列号定位目标键的最新可见内部版本，再判断类型和截止时间。如果该版本已过期，返回 NotFound 并结束查找，不能继续寻找更旧的普通值。这使过期记录具备屏蔽旧版本的作用。到期判断为 $t_{\text{read}} \geq deadline$，等于截止时间即失效。MemTable 在返回 NotFound 的同时返回“已命中”，SST 路径使用 kExpired 状态终止跨文件查找；因此不会因内存中的新值过期而读出 SST 中的旧值。有效 TTL 值返回时去掉 8 字节前缀；载荷不足 8 字节属于 Corruption，不能按正常到期处理。

例如先写入 a=old，再写入有效期较短的 a=new。new 到期后，当前读结果应为不存在；只有创建于第二次写入之前的快照仍可能读到 old。TTL 因而同时受到序列号和时间两个维度的约束。

2.3 快照与迭代器

SnapshotImpl 保存 sequence_number 和 read_time_micros。快照读使用这两个固定值；不带显式快照的迭代器也在创建时固定序列号与读时间；普通 Get 则为每次调用重新取时间。正向迭代遇到过期版本后跳过整个比较器等价键，反向迭代将该版本作为删除屏障，并在方向切换时维持同一读取视图。

显式快照通过 SnapshotList 提供序列号和时间保护；普通迭代器并不加入该列表，而是持有旧 MemTable 与 Version 引用以保留原始记录，并由活动迭代器计数阻止完整 GC 宣称完成。因此不能把“有迭代器”写成“后台合并全部停止”。最早序列号与最早读取时间分别计算，时间下界会遍历全部快照，不能假设最早序列号的快照同时拥有最早时间。

表 4　TTL 点读与旧版本屏蔽的伪代码

行号	伪代码
1	$(s, t) \leftarrow$ 本次读取的序列号与时间
2	$r \leftarrow$ 该视图内目标键的最新记录
3	**if** 没有匹配记录 **then return** NotFound
4	**if** r 为删除标记 **then return** NotFound
5	**if** r 为普通值 **then return** 用户值
6	**if** TTL 载荷不足 8 字节 **then**
7	**return** Corruption
8	$deadline \leftarrow$ 解码前 8 字节
9	**if** $t \geq deadline$ **then return** NotFound
10	**return** 去掉截止时间前缀后的用户值

注：语义级伪代码，假定内部键解析与底层读取成功。快照固定序列号和时间；命中删除或过期记录后结束查找，不能回退到该键更旧的值。

表 4 总结点读的终止条件与返回结果。

2.4 普通合并与底层重写的安全条件

普通 Compaction 对最新 TTL 屏障的删除要求同时满足：记录序列号不晚于最早受保护序列号、截止时间不晚于最早受保护读时间、IsBaseLevelForKey 确认更深层没有该键。若仍有更深层旧值，过期记录必须保留屏障作用。同一合并中的旧版本还可按常规序列号覆盖规则删除，不必逐条等待自身 TTL 到期。完整 GC 运行期间，序列号和时间边界还受其入口值限制。

最底层同层重写在存在显式快照，或完整 GC 期间已发生入口之后的写入时，保守保留所选输入记录。其他情况下，对范围内的每个键保留必要的最新记录，并可清理被最新记录遮蔽的旧版本。如果最新记录是删除标记或已过期 TTL，且上层 SST 没有覆盖该键的文件范围，则可连同该键在输入中的旧版本一起删除；如果上层文件范围重叠，则保留该删除标记或过期记录作为屏障。上层检查按文件范围保守判断，文件重叠也不等于实际存在同名记录。

手动 CompactRange 先刷盘，再确定最高数据层，并按需要重写最底层。底层范围重写按用户比较器解释两端，包含等于 begin/end 的键，只选择相交文件并保留边界文件中的范围外记录；全部记录可回收时允许不生成输出 SST。不能把“当前最高非空层”与固定的最底层混用，CompactRange 会先处理前者，再尝试后者的同层重写。

2.5 底层回收的执行优化

非零层文件按内部键有序且区间不重叠。底层重写改为通过两级迭代器顺序连接选中文件，避免每条记录都在多路归并器中比较；维护扫描设置 fill_cache=false，减少对前台数据块缓存的替换。此变化优化扫描过程，不改变 TTL 到期和快照保护规则。

在字节序比较器路径中，按键有序的统计差分先保存在私有缓冲区，容量上限为 $\min(\texttt{metadata_workspace_size}, 4\,\text{MiB})$；超过预算后转为有序临时文件。提交时若当前 Version 仍等于完整扫描的底层版本，只需检查 MemTable、imm 和输入集合之外的 SST 中是否还有该键；版本变化则回退到精确计数，避免把并发写入误当成已回收。

后台选中最底层候选后，可向后合并连续的安全相邻文件，整批最多 16 个。扩展要求上层没有相交文件、TTL 摘要有效且存在到期时间不晚于安全读时间的记录；遇到不满足条件的文件即停止扩展。候选评分不变，真正删除仍按逐记录规则执行。

底层重写仅在原 block_size 为默认 4096 字节时，将输出块调整为 8192 字节；显式指定的其他大小保持不变。块迭代器在 shared=0 时直接引用块内键，发生前缀拼接时再复制；记录长度检查使用 64 位加法，避免长度相加溢出。未开启 Profiler 时跳过逐记录计时对象构造，减少热路径开销。

2.6 后台候选评分与摘要回退

SST 的 `leveldb.internal-stats.v1` 块同时保存总记录数与 TTL 数、截止时间范围和 16 桶直方图；TTL 摘要并非独立于该 LDS1 统计块。摘要有效时，调度按安全时间估算过期量；摘要缺失或损坏时，以开启校验且不填充块缓存的内部扫描精确计数。摘要损坏不等于记录数为零，统计恢复也可能因此触发重建。

候选须有非零过期估计，且满足“过期量占全部内部记录至少 30%”或“安全时间已超过最早截止时间至少 60 秒”。分母包括普通记录，60 秒不是等待满该时间便必然删除的承诺。收益分数为候选文件大小乘过期比例，再除以估计 I/O；估计包含候选文件和目标下一层的重叠文件，不能当作实际磁盘读写量。由于估计只累计完整到期的直方图桶，截止时间跨度较大时可能长期低估过期量。

存在任何显式快照时，自动 TTL 候选扫描直接跳过。扫描引用当前 Version 后释放状态锁，完成时重新核对 Version、快照及待处理工作，失效候选不提交。无候选时，系统在通常情况下短暂合并 1 毫秒内的重复扫描；自动 TTL 任务成功结束但前后全局物理记录总数相等时，也会设置短暂负缓存，减少无进展的重复重写。该判断比较的是全局记录总数，不直接表示任务逐条记录的回收量；极限时钟值另作饱和处理。手动合并、刷盘和普通容量驱动合并绕过该缓存。这是机会式调度，没有按到期时间保证执行的独立定时器。

3 统计元数据与一致性设计

图 2 展示统计信息如何附着在主数据结构并随提交发布。WAL 对应写入持久化，MANIFEST 对应文件版本安装，并非每次写入都修改 MANIFEST。

3.1 方案比较与最终取舍

统计查询若每次扫描所有内部记录，容易实现精确口径，但代价随数据量增长；仅记录“当前可读键数”则不符合实验要求。我们维护全局记录数和去重键数，并在写入及回收时更新。

表 5　统计维护方案比较

方案	优点	主要代价
每次全量扫描	口径直接	查询成本随规模增长
全量内存键计数	按键更新方便	内存随不同键数增长
主数据计数与全局标量	复用内部记录；查询快	写入需判断键是否已存在；合并需精确差分

当前前台路径以主数据物理记录为依据：普通写入只需判断用户键是否已经存在，命中后立即停止；需要精确记录数的回收路径则查询局部计数索引或回退扫描。新增索引附着在每个 SST 中，不是独立辅助 LSM。MetadataIndex 仍被批次溢出、合并差分和重建的临时表读写及缓存复用；类中保留的辅助 LSM 代码不代表当前数据库仍采用该方案。Recover 明确拒绝带旧辅助元数据检查点、文件或提交记录的数据库，返回 NotSupported；这与缺少可选局部索引的旧 SST 可回退读取是两种不同的兼容边界。

3.2 写入提交与批次原子性

WriteInternal 首先验证外部批次，并通过写队列串行确定提交组及序列号。对于每个不同用户键，检查提交前是否存在物理记录；记录总数增加批次内操作数，仅当原计数为零时增加去重键数。相同键在一个批次出现多次，只增加一次去重键数。设提交组含 n 条操作，K 为组内原始字节去重后的键集合，$R(k)$ 为提交前的物理记录数，则

$$T' = T + n, \qquad D' = D + \sum_{k \in K} \mathbf{1}_{R(k)=0}.$$

该规则同时适用于普通值、TTL 值和删除标记。大批次键聚合超过工作区阈值时写入临时有序段并归并，避免必须在内存中保留整个批次的键集合。

实现先用已知最大键边界排除新键；写入键过滤器仅在默认字节序比较器下启用，且只覆盖启用时最大键边界之后的键。边界以内或自定义比较器路径不能直接套用过滤器的缺键结论。其余键由 HasPrimaryRecordsForKey 依次检查 MemTable、imm 和所有可能包含该键的 SST，任一来源命中即可停止，不再为普通写入累加完整记录数。失败写入留下的额外过滤标记最多增加查找次数，不得把已有键判为不存在。

WAL 追加及按需 Sync 成功后，批次插入 MemTable。重新持有状态锁后，再发布计数和最新序列号。失败路径不发布成功统计；Sync 失败会记录后台错误，阻止后续写入继续建立在不确定的持久化状态上。

为降低短时间写队列等待的切换成本，满足非同步写、可用 CPU 数和后台压力等条件时，少量等待线程可先短暂自旋；未获得执行机会时仍通过条件变量等待。组批时同步识别可信单条 Put 组，以减少后续重复遍历。该优化不改变批次提交与统计发布语义。

3.3 统计查询的快速路径

常见计数范围内，将 total_entries、distinct_keys 和 seq 分别用 21、19、23 位编码进一个 64 位原子值，最高位标识回退。三个字段各自的上限分别为 $2^{21}-1$、$2^{19}-1$ 和 $2^{23}-1$。一次原子读取即可获得完整统计，不需要扫描数据或依次读取三个独立字段。

任一字段超过其对应的紧凑快照上限时，改用版本号保护的宽统计快照：T、D 各占 32 位并打包，S 单独保存在 64 位原子变量中。读者要求前后版本号相同且为偶数，并通过 acquire/release 屏障配合载荷读写；版本变化时重试。若 T 或 D 超过 $2^{32}-1$，或发布快照不可用，则进入加锁路径。因而“序列号超过 23 位”和“计数超过 32 位”触发的是不同层级的回退。

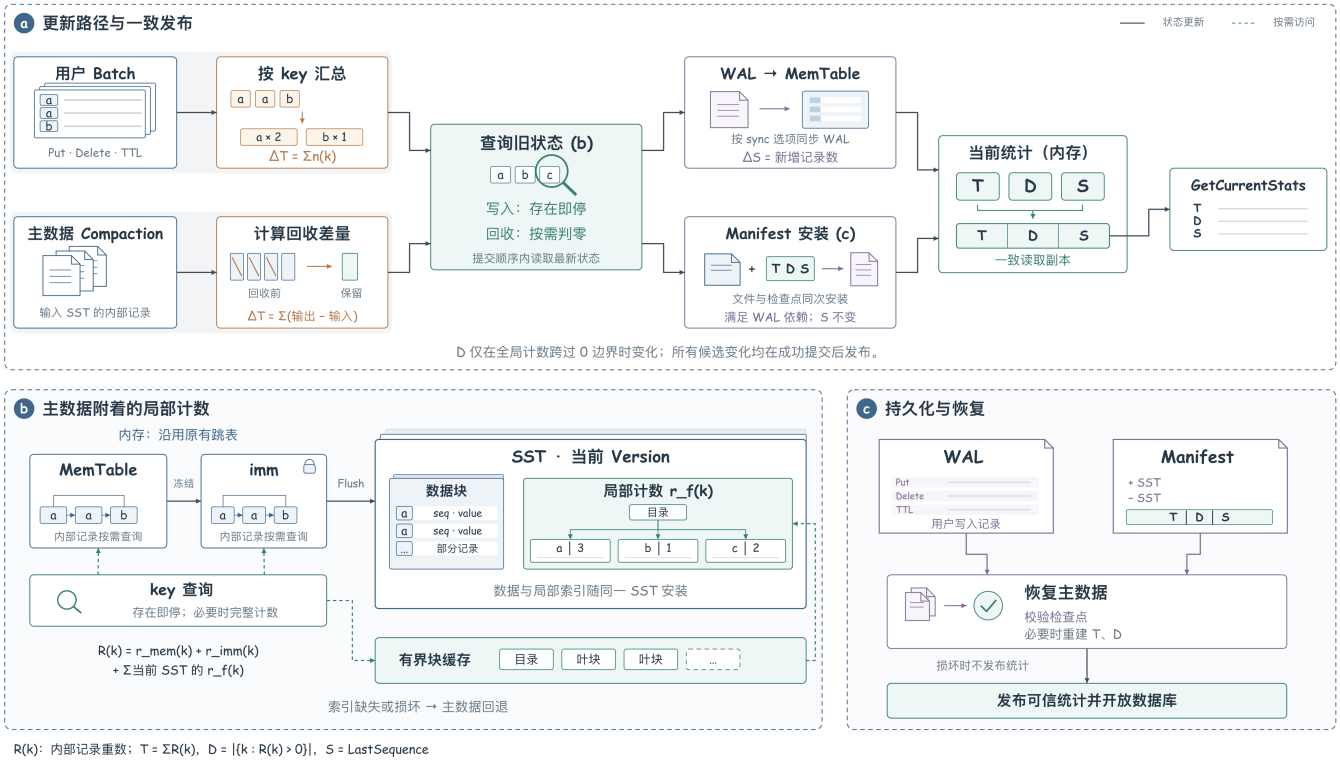


图 2　主数据附着式统计与当前状态查询总览（作者提供）。(a) 更新路径与一致发布；(b) 主数据附着的局部计数；(c) 持久化与恢复。T、D、S 分别为记录数、去重键数和发布序列号。写入按需判断键是否存在，回收按需精确计数。(c) 为正常恢复主线；受限只读分支见第 4.3 节，图中损坏保护不涵盖所有畸形 WAL 批次。

这项优化降低频繁查询对写入锁的竞争，但不意味着所有计数规模都只需要一次原子加载。空指针参数返回 InvalidArgument；重建期间的查询等待或回退，避免读到未完成统计。

表 6　紧凑统计快照的读取

行号　执行语句

```
1  const uint64_t compact_snapshot =
2      published_stats_compact_snapshot_.load(
3          std::memory_order_relaxed);
4  if ((compact_snapshot & kCompactStatsFallback) == 0) {
5    stats->total_entries =
6        compact_snapshot & kCompactStatsTotalMask;
7    stats->distinct_keys =
8        (compact_snapshot >> kCompactStatsTotalBits)
9        & kCompactStatsDistinctMask;
10   stats->seq = compact_snapshot >>
11       (kCompactStatsTotalBits +
12        kCompactStatsDistinctBits);
13   return Status::OK();
14 }
15 return GetCurrentStatsWideSnapshot(stats);
```

注： 摘自 `db/db_impl.h` 的 GetCurrentStatsSnapshot 函数体，仅调整换行。三个字段来自同一原子值；置位回退标志时转入宽统计路径。

表 6 给出紧凑快照的读取代码，完整回退条件如上所述。

3.4 Compaction 统计差分

回收按用户键汇总输入、输出记录差分。total_entries 随实际移除的内部记录减少；distinct_keys 只有在当前数据库中该原始字节键的记录数从非零变为零时才减少。某个文件中不再出现该键，并不代表其他层或 MemTable 中也没有该键。

表 7　无回收时的统计示例

操作	记录数	键数	seq
空库	0	0	0
Put(a,1)	1	1	1
Put(b,1)	2	2	2
Put(a,2)	3	2	3
Delete(b)	4	2	4

提交合并结果时，主 Version 和全局计数构成同一个发布状态。对于有记录变化的合并，代码协调写提交，等待正在进行的 WAL 组完成，再针对仍为当前的 Version 判断可能归零的键，并安装版本编辑。文件增删与新计数检查点写入同一个 VersionEdit；LogAndApply 成功后才更新内存标量并发布统计，合并本身不推进用户序列号。

上述提交边界防止 SST 构建或 MANIFEST 写入失败时提前扣除记录。若某键仍有输出记录，去重键数

不变，无需再查该键；只有输出为零且发生记录减少时，普通合并才检查当前总数是否恰好等于移除量。已完整扫描且 Version 未变的底层路径，则检查输入之外是否仍有记录。两条路径都纳入并发写入，不能只用合并开始时的计数快照。没有统计差分的合并可跳过这一写提交阻塞阶段。

3.5 SST 逐键局部计数索引

主数据 SST 的 metaindex 新增 `leveldb.local-counts.v1`，指向独立描述符块。描述符包含 LCI1 标识、树高、不同原始键数、物理记录总数与根块位置；它与文件级内部统计块分别校验；本次局部索引扩展不再改动 Footer、主记录编码与 MANIFEST 格式，但主数据统计方案本身已经增加了 MANIFEST 检查点字段。索引在刷盘、普通合并、底层重写和 RepairDB 的主数据输出中构建，通用 TableBuilder 和临时元数据表不启用。

计数树叶块存储“原始键 → fixed64 计数”，目录块存储“子块最大键 → BlockHandle”，均按字节序排序，目标块大小为 4 KiB，最多 32 层；4 KiB 是分块目标，单个长键可能使块超过该值，并非硬上限。默认字节序输入可流式聚合；自定义比较器下，按工作区预算生成带 CRC 的有序临时段，再最多 8 路归并。比较器判等但原始字节不同的键仍分别计数，旧版本、删除标记和未回收 TTL 记录均计入。

打开 SST 只读取小描述符，不预加载整棵计数树。局部计数块使用 metadata_cache_size 的一半作为缓存预算，剩余一半分给既有元数据缓存。缓存键包含全局唯一 Table 实例号和块偏移，避免重开或文件编号复用时命中旧内容；条目按实际保留容量计费，超出分片准入预算的大块直接读取。该预算约束缓存 charge，不代表整个进程的 RSS 上限。

旧 SST 缺失索引，或索引版本未知、CRC/结构校验失败时，禁用该 Table 实例的可选索引，并整体回退到验证主目录与数据块校验和的迭代器。零计数必须来自成功的索引查询或成功的主数据回退查询，不能把错误当成缺键。回退按用户比较器定位等价区间，再用原始字节确认目标键；存在性查询命中即停，精确计数遍历该键全部版本。主目录与实际读取的数据块校验失败必须向上传播，不能将这一按需检查描述为整库完整性证明。

“可选”描述的是已有 SST 的读取回退能力。构建新 SST 时，局部索引聚合、临时段或写块失败仍会使 TableBuilder 失败，不能安装该输出。文件级 `leveldb.internal-stats.v1` 摘要与逐键树分工不同：前者保存总记录数及 TTL 摘要，当前 LDS1 版本 2 不内嵌完整键计数表；后者加速逐键存在性和计数查询。GetCurrentStats 直接读取已发布标量，不逐次访问这棵树。原样 Flush 不改变全局计数，索引构建也不消耗用户序列号。

4 持久化恢复与完整 GC

4.1 恢复路径

TTL 截止时间属于记录本身，随 WAL、MemTable 和 SST 传递。恢复 WAL 时重放绝对截止时间；重新打开数据库不会为原记录延长有效期。恢复后的时间判断仍使用配置的 Env，便于用可控时钟验证边界。

统计恢复先检查 MANIFEST 的主数据检查点：要求检查点序列号不超过已记录的最新序列号，且总记录数不小于去重键数，并验证当前 SST 的内部统计块。严格模式还逐表读取数据块并校验；宽松模式不能因此宣称已验证全部主数据。WAL 重放遇到结束序列号超过检查点的非空批次时，会标记统计需要重建，而不是仅把日志操作数加到旧计数上。

RebuildMetadata 使用开启校验的内部迭代器扫描物理记录，包含删除标记、旧版本与过期值，同时重新计算 T 与 D。默认字节序下按相邻键去重；自定义比较器下使用按原始字节排序的临时段与最多 8 路归并。只有完整扫描成功才替换全局计数并持久化检查点。该恢复成本与主数据规模有关，不能由“统计查询不扫描”推导为“重开也不扫描”。

文件损坏、读取错误和校验错误不应解释为“该文件记录数为零”。可选局部索引故障会回退主数据计数；检测到的主数据错误按所在恢复分支处理，精确统计重建失败时可按第 4.3 节进入受限只读状态。但该保护尚未覆盖所有畸形 WAL 批次。版本提交失败不能发布已完成回收的统计；已有故障测试覆盖部分 WAL、SST 和 MANIFEST 失败场景。

4.2 完整 GC 的可验证语义

RunFullGC 返回 Status 和 GCResult。进入时捕获 entry_sequence 与 entry_time_micros，以固定边界验证清理结果。Status::OK 只表示本次执行没有返回错误；只有 complete=true 才表示能证明该边界上的安全回收完成。

表 8　GCResult 的主要字段

字段	含义
complete	本次可证明完成回收
snapshots_blocked	观察到显式快照保护
iterators_blocked	观察到用户迭代器占用
concurrent_state_changed	并发写入或版本变化影响完成证明

实现先对入口 Version 的 SST 进行校验，再调用全范围整理；有资格声明完成时，还重新打开整理后 SST，避开可能未经校验进入共享缓存的块，再以内部迭代器检查重复版本、删除标记和入口时已过期记录。入口与结束阶段观测到快照、活动迭代器，或检测到并发写入及相关 Version 变化，都会阻止完成声明。另一项完整 GC

正在执行时，本次直接以 concurrent_state_changed 返回未完成；I/O、校验与后台错误通过 Status 返回。

complete 的参照时间是入口时间，不是函数返回时间。若记录在入口时仍有效、执行中才到期，本次可以保留它并返回 complete=true；此时当前 Get 已可返回 NotFound，物理统计仍包含该记录，下一次完整 GC 才会将其纳入到期回收范围。即使没有受保护视图，保守重写后仍留有重复版本也会使复核结果为未完成，不能将该接口理解为一次调用必然清空所有冗余记录。

4.3 损坏数据库的受限只读恢复

系统对精确统计重建失败进行了明确处理：当 RebuildMetadata 返回 Corruption 且 paranoid_checks=false 时，Open 可以成功返回一个受限只读对象，以便继续尝试读取完整记录。此时保留后台损坏状态，不发布部分统计，不启动正常后台维护；GetCurrentStats、写入和 RunFullGC 返回损坏错误，GC 不报告完成。读取也可能遇到损坏，不能把 Open 成功解释为数据完整。

若启用 paranoid_checks，或重建失败属于其他错误，则不使用该宽松恢复分支。修复后需重新打开数据库才能恢复正常操作。这一边界同时写入公开 DB::Open 注释。CMake 的 Zstd 检测符号改为大小写正确的 ZSTD_compress，使安装了对应库的环境能够正确检测并执行压缩相关测试。

5 正确性测试

5.1 测试组织与验证目标

正确性测试分为课程公开测试、项目新增定向测试和 LevelDB 原生回归三层。课程测试检查 TTL、统计接口及二者的联合行为；定向测试针对边界、并发、故障和恢复构造更细的场景；原生回归检查数据库原有功能、C 接口和 Env 接口。三层测试分别从接口契约、关键实现路径和兼容性验证系统。

表 9　正确性测试的分层与检查内容

测试层次	主要检查内容
课程 TTL 测试	TTL 接口、到期读写、快照及迭代器视图
课程统计测试	内部记录计数、不同键数、序列号及重开恢复
课程联合测试	混合覆盖、批次、快照、回收、重开和并发统计
新增定向测试	边界时间、二进制键、局部索引、故障注入和随机模型
原生兼容回归	原生数据库行为、C API 和 Env 接口

5.2 课程公开测试

课程公开测试包括两项 TTL 专项、两项统计专项和六项联合正确性场景。TTL 专项检查过期读取及固定视图；统计专项检查计数契约和重开后的统计。六项联合测试分别覆盖基本接口、覆盖与删除、快照和迭代器、重开恢复、过期回收以及并发写入时的统计查询。

联合测试将普通写入、TTL 写入与删除组合起来，验证记录到期后读取结果发生变化，而统计只有在记录被实际回收并成功安装后才减少；同时检查回收不推进用户序列号。重开场景分别检查 WAL 和 SST 路径，确认截止时间与统计结果得到恢复。并发场景持续读取统计，检查同一批次不会只发布部分结果。

5.3 新增定向测试

在公开测试基础上，项目围绕以下关键问题补充测试。

1. **时间边界与读取视图**。检查零 TTL、恰好到期、截止时间溢出、旧值屏蔽，以及快照和双向迭代器在到期与回收前后的读取。混合批次示例中，写入后统计为 $(6, 3, 6)$；释放视图并完成 GC 后，只保留永久值，统计变为 $(1, 1, 6)$，重开后保持一致。

2. **统计更新与并发**。测试同键跨 MemTable、imm 和 SST 的计数、批次内重复键，以及合并期间同键写入；检查 T、D、S 按整体发布。另通过随机操作序列与独立模型对照，检查读取结果和静止状态下的物理记录统计。

3. **局部索引与特殊键**。测试 SST 局部计数索引的构建、查询、多层结构、缓存淘汰与损坏回退，并覆盖空键、二进制键和自定义比较器下的原始字节判等。可选索引不可用时从主数据计数，主数据读取失败时返回错误。

4. **回收、故障与恢复**。检查底层重写、部分范围回收、摘要缺失或损坏、显式快照保护和完整 GC 的结果；注入 WAL、SST 同步及 MANIFEST 写入失败，并在进程终止后检查恢复，确认失败安装不会提前发布回收减量。

上述具体数值属于测试代码中的断言，用于说明测试内容；实际通过情况以对应运行记录为准。

5.4 测试结果

三组对照实验共完成 372 次课程场景运行，全部通过；其中包含正确性及性能场景。当前实现的固定版本原生回归连续三轮均为 211/211 通过，C 接口回归三轮通过，Env 回归三轮均为 7/7 通过。[1]

6 性能测试与结果分析

6.1 测试方案与评价指标

性能测试采用课程公开 benchmark，同时考察普通读写、TTL 和元数据统计。对比包括课程初始实现、TTL 与元数据统计功能加入后的早期实现和当前实现。课程

初始实现不支持 TTL 与统计接口，因此只参加共有普通性能场景的比较；专项场景比较后两种实现。[1]

实验在同一机器上使用独立 Release 构建，启用 Snappy 和 Zstd。测试规模为 1 万和 10 万键，适用场景使用 1 或 8 个线程，TTL 场景覆盖 0%、50% 和 100% 过期比例，值大小为 256 字节。各配置运行三次，使用相同参数和对应随机种子，交替运行各实现，表中给出三次吞吐量的中位数。共完成 372 次场景运行，覆盖 80 个性能阶段与配置。[1]

课程 benchmark 的性能项包括普通写入、并发写入、命中与未命中读取、扫描和数据库重开；TTL 专项测量 TTL 写入、混合读取与完整回收；统计专项测量统计查询和写入期间的查询；联合场景测量 TTL 写入与统计查询、不同过期比例下的联合回收。吞吐量包含测试驱动的工作，GC 阶段使用配置键数除以阶段耗时，表示阶段处理率。

6.2 普通读写与恢复性能

表 10 展示 10 万键场景下的主要结果。当前实现的单线程写入、八线程并发写入、命中读取和数据库重开吞吐均高于两个对照实现；扫描吞吐与课程初始实现接近。重开指标的单位为次/s，其余为操作/s。[1]

表 10　10 万键普通性能场景的吞吐量中位数

场景	课程初始	附着初期	当前实现
单线程写入	101,562	63,997	482,424
八线程并发写入	66,632	47,851	163,066
命中读取	689,408	643,243	909,688
扫描	2,593,240	2,329,820	2,579,180
数据库重开（次/s）	112.67	66.13	252.79

当前实现的普通单线程写入较课程初始实现提高 375.00%，八线程并发写入提高 144.73%；重开吞吐提高 124.38%。这些结果反映不同实现整体的表现，不能将差异单独归因于某一项优化。

6.3 TTL 与统计专项性能

表 11 比较具备 TTL 和统计功能的两个实现。10 万键 TTL 写入吞吐由 63,324 提高到 470,104 次/s；八线程写入期间统计查询由 7,566,200 提高到 19,438,400 次/s。TTL 完整 GC 和 50% 过期比例下的联合 GC 阶段处理率也有明显提高。[1]

TTL 完整 GC 和联合 GC 的数字是基于配置键数计算的阶段处理率，不表示磁盘实际每秒执行的 I/O 次数。统计查询与写入的并发测试分别记录两类操作，能够同时观察查询速度和查询对写入的影响。

6.4 结果分析与补充测试

性能并非在所有配置下都提高：1 万键、8 线程且并发查询统计时，写入吞吐从 54,733.60 降至 50,914.00 次/s，下降 6.98%；1 万键重开和扫描分别比课程初始实现低 4.34% 和 2.02%。这些差异基于三次中位数，仍需通过更多重复实验观察波动。[1]

表 11　10 万键 TTL 与统计场景的吞吐量中位数

场景	附着初期	当前实现	变化
TTL 写入	63,324	470,104	+642.38%
写入期间统计查询（8 线程）	7,566,200	19,438,400	+156.91%
TTL 完整 GC	279,024	4,321,590	+1448.82%
联合 GC（50% 过期）	354,877	1,916,900	+440.16%

资源方面，10 万键单线程普通写入的峰值 RSS 中位数分别为课程初始实现 30,540 KiB、附着初期 30,732 KiB、当前实现 41,404 KiB。RSS 包含测试驱动、数据模型和缓存，反映进程整体内存而非数据库独占内存。[1]

除课程 benchmark 外，项目还提供针对局部计数索引的定向微基准，分别观察索引构建、文件空间和冷暖查询成本；已有记录显示，键的版本密度会影响额外索引空间及查询收益。这些定向实验帮助分析成本来源，不能直接替代整库性能测试。后续可增加重复次数，并结合阶段耗时、缓存命中和 I/O 指标分析写入与回收中的具体开销。

7 实验问题与解决方法

7.1 过期记录与统计口径冲突

最容易混淆的是“用户读不到”和“物理记录不存在”。如果在 Get 判断到期时直接扣减统计，多个读线程可能重复扣减，时间流逝也会改变统计却没有对应版本提交。实现上，Get 和迭代器的过期过滤只影响读取可见性，不直接扣减物理统计；合并与底层重写仍按过期时间、快照和版本屏障判断能否删除。回收造成的统计减量与对应文件变更一起提交，安装成功后才发布。

7.2 范围回收与空输出

最底层重写必须处理只清理部分键、边界文件同时包含范围内外记录，以及全部过期后无输出文件的情况。当前实现限定重写文件集合，按比较器保留范围外记录，并将输出文件编号初始化为 0，避免空输出时使用未初始化值。范围测试检查可见性、物理计数与不相交文件身份；空输出另经源码检查，上述测试不代表所有空输出分支均已覆盖。

7.3 并发与持久化失败

合并准备期间，同一用户键可能被前台再次写入。如果按旧状态计算 distinct_keys 的减量，就会把仍有新记录的键错误扣除。实现通过 BeginMetadataCommit 暂停新的写提交，并等待正在进行的 WAL 写入完成；只有本次合并不再输出的键，才需要查询当前主数据，核对全局物理计数是否从非零变为零。文件变更与统计检

查点通过同一 VersionEdit 安装，成功后更新已发布统计。并发同键写入测试在 SST 同步处暂停合并，再插入新值，验证读取和物理统计仍一致。

文件创建成功不代表版本提交成功。当前 SST 同步或 MANIFEST 安装失败时，不发布这次失败安装的文件变更和统计减量；这不意味着回滚整个 GC 中此前已成功提交的步骤。错误的对外呈现依接口而异：RunFullGC 返回失败 Status 并将 complete 置为 false；返回 void 的 CompactRange 记录后台错误，不能直接向调用者返回 Status。故障注入分别覆盖普通合并和底层重写的 SST Sync、MANIFEST Append 失败，并检查发布状态与恢复行为；这些用例不构成对所有存储故障的完整覆盖。

8 实验总结

本实验的主要收获是将可见性、物理保存状态和持久化提交分开建模：TTL 决定读取结果，当前 Version 决定统计范围，成功提交决定发布时机。三者的边界明确后，零 TTL、旧版本屏蔽、快照保护和回收计数才能形成一致的实现。

本文结合当前实现说明 TTL 可见性、截止时间持久化、快照保护与完整 GC 接口。后续应先补齐恢复与调度缺口，再降低局部索引构建和冷块校验成本、跟踪联合 GC 回退。已有测试通过不等于完整正确性证明；仍需在相同配置下进行完整性能复测，不能将既有批次的结论扩展到所有键分布和硬件。

附录复现入口与证据索引

A 构建和运行

建议在 Linux 或 WSL2 的 Linux 文件系统中构建和测试，使用 CMake 3.22+、支持 C++17 的编译器及 Python 3.9+。复现本文实现应先取得远程仓库中的源码；以下点号表示该源码根目录。课程测试应在独立数据库目录运行，每次 benchmark 使用全新输出目录。

表 12 构建与原生测试命令

行号	执行语句
1	`cmake -S . -B build \`
2	`  -DCMAKE_BUILD_TYPE=Debug \`
3	`  -DLEVELDB_BUILD_TESTS=ON \`
4	`  -DLEVELDB_BUILD_BENCHMARKS=OFF`
5	`cmake --build build -j2`
6	`ctest --test-dir build --output-on-failure`
7	`./build/ttl_test`
8	`./build/metadata_test`

注： 在远程仓库根目录的 Linux shell 中执行，反斜杠表示续行。Debug 构建启用测试并关闭基准程序；`ctest` 在失败时输出日志。

表 12 给出构建与测试入口。第 6 行仅运行已注册的 CTest 测试；课程独立程序未注册到 CTest，故第 7、8 行须单独执行。专项测试可通过 leveldb_tests 的 gtest_filter 选择 TTLMetadataTest。第 5.4 节列出不同批次的实际执行结果。压缩库缺失会使部分原生测试跳过，应检查跳过原因，而非只看 CTest 的成功状态。

表 13 联合基准测试命令

行号	执行语句
1	`python3 benchmark/runner.py \`
2	`  --kind combined --source . \`
3	`  --output /tmp/leveldb-report-run-001 \`
4	`  --profile standard --matrix \`
5	`  --repeat 3 --jobs 2`

注： 从仓库根目录运行；输出目录为示例路径，每次应换用全新目录。此处为当前源码的 3 次重复运行示例。正文三组对照需要分别准备对应源码并按相同参数运行；实验口径与原始数据见 [1]。

联合基准测试入口见表 13。检查 summary.json 的 full_suite、status 与 regression，并结合 aggregate.json、metrics.csv 查看重复结果。各场景的测试配置和测量结果见 [1]。

B 实验结果文件

以下文件位于仓库的 doc/THREE_VERSION_BENCHMARK_20261105/ 目录。[1]

`REPORT.md`：实验方法、测试结果和性能分析。

`metrics-raw.csv`：各轮场景的原始性能数据。

`metrics-median.csv`：各配置的中位数与波动范围。

`peak-rss.csv`：各场景的进程峰值内存数据。

`benchmark-summary.json`：场景运行汇总。

`regressions-summary.json`、regression-followup-summary.json：原生回归及补充验证结果。

`run-manifest.json`：实验配置和运行记录。

附录 C 三组实验数据中位数

本附录汇总课程初始实现、功能加入后的早期实现和当前实现的全部已记录中位数。每项配置重复三次；数据来自附录 B 的 `metrics-median.csv` 与 `peak-rss.csv`。初始实现不支持 TTL 和统计接口，因此相应场景没有数据。各指标分别取三次运行的中位数，不保证对应同一次运行。

表中 N 为配置键数或操作规模，线程数和过期率为运行参数；不适用过期率的场景仍保留运行器记录的参数。吞吐量单位为操作/s，重开场景为次/s；耗时单位为 s，延迟单位为 μs。GC 吞吐量按配置键数除以阶段耗时计算。写入量为测量阶段的追加字节数，目录大小为排空后的数据库目录字节数，均非物理设备 I/O。峰值 RSS 的单位为 KiB，包含测试驱动和缓存。表中按原始数据保留数值精度；重复运行的最小值和最大值见附录 B 数据文件。

C.1 性能场景与阶段编号

编号	场景	阶段
P01	`perf_combined_gc`	`ttl_gc_with_statistics`
P02	`perf_combined_stats_under_write`	`stats_under_ttl_write`
P03	`perf_combined_stats_under_write`	`ttl_put_with_stats_queries`
P04	`perf_combined_stats_under_write`	`ttl_put_without_stats_queries`
P05	`perf_concurrent`	`parallel_put`
P06	`perf_read`	`get_hit`
P07	`perf_read`	`get_miss`
P08	`perf_reopen`	`open`
P09	`perf_scan`	`scan`
P10	`perf_stats`	`stats_query`
P11	`perf_stats_under_write`	`put_with_stats_queries`
P12	`perf_stats_under_write`	`put_without_stats_queries`
P13	`perf_stats_under_write`	`stats_under_write`
P14	`perf_ttl_gc`	`ttl_full_gc`
P15	`perf_ttl_mixed`	`ttl_mixed_get`
P16	`perf_ttl_write`	`ttl_put`
P17	`perf_write`	`put`

C.2 性能指标中位数

表 14　各性能阶段的三次运行中位数

编号	N	线程	过期%	实现	吞吐量	耗时	p50	p95	p99	写入字节	目录字节
P01	10000	1	0	早期	316939	0.0315518	31551.1	31551.1	31551.1	2814090	2839675
P01	10000	1	0	当前	659388	0.0151656	15159.8	15159.8	15159.8	3110822	3127143
P01	10000	1	50	早期	274626	0.0364132	36412.4	36412.4	36412.4	1521762	1432844
P01	10000	1	50	当前	763176	0.0131031	13102.5	13102.5	13102.5	1555602	1571924
P01	10000	1	100	早期	278003	0.0359709	35970.2	35970.2	35970.2	229200	25229
P01	10000	1	100	当前	1877690	0.00532569	5325.02	5325.02	5325.02	30	16353
P01	100000	1	0	早期	461482	0.216693	216692	216692	216692	28141412	28297111
P01	100000	1	0	当前	1201120	0.0832554	83254.4	83254.4	83254.4	31106623	31182999
P01	100000	1	50	早期	354877	0.281788	281782	281782	281782	15217588	14228396
P01	100000	1	50	当前	1916900	0.0521675	52166.6	52166.6	52166.6	15553418	15629795
P01	100000	1	100	早期	280561	0.356429	356428	356428	356428	2294330	158823
P01	100000	1	100	当前	4299590	0.023258	23251.1	23251.1	23251.1	129	76507
P02	10000	1	0	早期	10092200	0.14686	0.051	0.054	0.087	5769235	5658527
P02	10000	1	0	当前	19791900	0.0208093	0.03	0.031	0.098	3030567	6166358
P02	10000	1	50	早期	9928650	0.147807	0.051	0.06	0.091	5769235	5658528
P02	10000	1	50	当前	19383400	0.0211321	0.03	0.031	0.078	3030567	6166359
P02	10000	1	100	早期	10232200	0.146924	0.051	0.053	0.088	5769235	5658529
P02	10000	1	100	当前	19741600	0.021061	0.03	0.031	0.087	3030567	6166360
P02	10000	8	0	早期	6999120	0.176534	0.051	0.057	0.09	8022482	5655015
P02	10000	8	0	当前	17213900	0.0627564	0.032	0.048	0.076	2886911	6026016
P02	10000	8	50	早期	7221120	0.176487	0.051	0.056	0.088	8022475	5654509
P02	10000	8	50	当前	17395500	0.0625325	0.032	0.047	0.076	2887815	6026864
P02	10000	8	100	早期	7475910	0.183521	0.051	0.053	0.085	8027585	5655170
P02	10000	8	100	当前	16324700	0.0642011	0.032	0.047	0.073	2887634	6027063
P02	100000	1	0	早期	7626500	1.63628	0.051	0.053	0.095	58377475	56445182
P02	100000	1	0	当前	19310200	0.217366	0.03	0.032	0.073	61120076	62539100
P02	100000	1	50	早期	7900800	1.64452	0.051	0.052	0.063	58377475	56452036
P02	100000	1	50	当前	19517700	0.227455	0.03	0.031	0.082	61120076	62539101

编号	N	线程	过期%	实现	吞吐量	耗时	p50	p95	p99	写入字节	目录字节
P02	100000	1	100	早期	7718790	1.6504	0.051	0.052	0.065	58377475	56453654
P02	100000	1	100	当前	19061800	0.207368	0.03	0.045	0.079	61120076	62539102
P02	100000	8	0	早期	7319470	2.22243	0.051	0.055	0.084	101630325	56436986
P02	100000	8	0	当前	17088500	0.639124	0.032	0.049	0.065	59713784	62522567
P02	100000	8	50	早期	7429520	2.25246	0.051	0.054	0.087	107092190	56439913
P02	100000	8	50	当前	17203800	0.639486	0.032	0.047	0.061	59715739	62522579
P02	100000	8	100	早期	7339910	2.20679	0.051	0.053	0.09	102458095	56447376
P02	100000	8	100	当前	17320100	0.645695	0.032	0.047	0.071	59717591	62523199
P03	10000	1	0	早期	68074.9	0.146897	0	0	0	5769162	5658527
P03	10000	1	0	当前	479689	0.0208468	0	0	0	3030567	6166358
P03	10000	1	50	早期	67637	0.147848	0	0	0	5769162	5658528
P03	10000	1	50	当前	472172	0.0211787	0	0	0	3030567	6166359
P03	10000	1	100	早期	68040.4	0.146971	0	0	0	5769162	5658529
P03	10000	1	100	当前	473818	0.0211051	0	0	0	3030567	6166360
P03	10000	8	0	早期	56568.5	0.176777	0	0	0	7227673	5655015
P03	10000	8	0	当前	158870	0.0629446	0	0	0	2890225	6026016
P03	10000	8	50	早期	56611.3	0.176643	0	0	0	7403425	5654509
P03	10000	8	50	当前	159445	0.0627176	0	0	0	2891072	6026864
P03	10000	8	100	早期	54436.2	0.183701	0	0	0	7801984	5655170
P03	10000	8	100	当前	155107	0.0644718	0	0	0	2891270	6027063
P03	100000	1	0	早期	61112.7	1.63632	0	0	0	58377399	56445182
P03	100000	1	0	当前	459967	0.217407	0	0	0	56658526	62539100
P03	100000	1	50	早期	60805.9	1.64458	0	0	0	58377399	56452036
P03	100000	1	50	当前	439557	0.227502	0	0	0	56931593	62539101
P03	100000	1	100	早期	60589.6	1.65045	0	0	0	58377399	56453654
P03	100000	1	100	当前	482117	0.207419	0	0	0	56869298	62539102
P03	100000	8	0	早期	44992.2	2.22261	0	0	0	100274520	56436986
P03	100000	8	0	当前	156403	0.639372	0	0	0	57153850	62522567
P03	100000	8	50	早期	44390.8	2.25272	0	0	0	105958144	56439913
P03	100000	8	50	当前	156330	0.639671	0	0	0	57295053	62522579
P03	100000	8	100	早期	45310.7	2.20698	0	0	0	101558312	56447376
P03	100000	8	100	当前	154828	0.645878	0	0	0	56988546	62523199
P04	10000	1	0	早期	68798.4	0.145352	0	0	0	5769162	5658527
P04	10000	1	0	当前	484948	0.0206208	0	0	0	3030567	6166358
P04	10000	1	50	早期	69049.7	0.144823	0	0	0	5769162	5658528
P04	10000	1	50	当前	476541	0.0209845	0	0	0	3030567	6166359
P04	10000	1	100	早期	69249.6	0.144405	0	0	0	5769162	5658529
P04	10000	1	100	当前	483207	0.020695	0	0	0	3030567	6166360
P04	10000	8	0	早期	57052.3	0.175278	0	0	0	7080622	5654895
P04	10000	8	0	当前	163399	0.0612	0	0	0	2889256	6025047
P04	10000	8	50	早期	57412.4	0.174179	0	0	0	7137661	5654345
P04	10000	8	50	当前	164058	0.0609542	0	0	0	2889047	6024839
P04	10000	8	100	早期	57440.3	0.174094	0	0	0	6802483	5654551
P04	10000	8	100	当前	165081	0.0605764	0	0	0	2889294	6025087
P04	100000	1	0	早期	62384.1	1.60297	0	0	0	58377399	56454653
P04	100000	1	0	当前	466239	0.214482	0	0	0	56890063	62539100
P04	100000	1	50	早期	62515.2	1.59961	0	0	0	58377399	56462585
P04	100000	1	50	当前	440008	0.227269	0	0	0	56964470	62539101
P04	100000	1	100	早期	62592.5	1.59764	0	0	0	58377399	56464896
P04	100000	1	100	当前	495001	0.20202	0	0	0	56952062	62539102
P04	100000	8	0	早期	45144.2	2.21512	0	0	0	99664689	56443733
P04	100000	8	0	当前	162999	0.6135	0	0	0	57047595	62523039
P04	100000	8	50	早期	45392.7	2.203	0	0	0	99038527	56433229
P04	100000	8	50	当前	164066	0.60951	0	0	0	57045789	62521943
P04	100000	8	100	早期	45594.3	2.19326	0	0	0	100818526	56445051
P04	100000	8	100	当前	162541	0.615228	0	0	0	57024687	62522368
P05	10000	1	50	初始	115213	0.0867961	0	0	0	5639813	2748356
P05	10000	1	50	早期	69953.7	0.142952	0	0	0	5642345	2751735
P05	10000	1	50	当前	501160	0.0199537	0	0	0	2950595	2959127
P05	10000	8	50	初始	87837.3	0.113847	0	0	0	7461620	2747565
P05	10000	8	50	早期	59082.7	0.169254	0	0	0	6840598	2748346
P05	10000	8	50	当前	165416	0.0604536	0	0	0	2808963	2817495
P05	100000	1	50	初始	102516	0.975458	0	0	0	56623206	27390705
P05	100000	1	50	早期	64410.4	1.55254	0	0	0	56648737	27425476
P05	100000	1	50	当前	491447	0.203481	0	0	0	52806382	28687110
P05	100000	8	50	初始	66632.1	1.50078	0	0	0	97849763	27396931
P05	100000	8	50	早期	47851.4	2.0898	0	0	0	95391471	27398989
P05	100000	8	50	当前	163066	0.61325	0	0	0	51508956	28685553
P06	10000	1	50	初始	855678	0.0116866	0.976	1.599	2.039	0	2745245
P06	10000	1	50	早期	808704	0.0123655	1.047	1.534	2.027	0	2748912
P06	10000	1	50	当前	1184140	0.00844496	0.653	1.021	1.35	0	2876126
P06	100000	1	50	初始	689408	0.145052	1.223	1.891	2.339	0	27373994
P06	100000	1	50	早期	643243	0.155462	1.331	1.975	2.368	0	27409053
P06	100000	1	50	当前	909688	0.109928	0.875	1.376	1.778	0	28684971
P07	10000	1	50	初始	3523570	0.00283803	0.272	0.282	0.287	0	2745245

编号	N	线程	过期%	实现	吞吐量	耗时	p50	p95	p99	写入字节	目录字节
P07	10000	1	50	早期	2647340	0.00377738	0.362	0.372	0.397	0	2748912
P07	10000	1	50	当前	4821930	0.00207386	0.193	0.202	0.205	0	2876126
P07	100000	1	50	初始	3222810	0.0310289	0.297	0.309	0.315	0	27373994
P07	100000	1	50	早期	2514250	0.0397734	0.382	0.393	0.398	0	27409053
P07	100000	1	50	当前	4797060	0.0208461	0.193	0.205	0.209	0	28684971
P08	10000	1	50	初始	115.645	0.00864716	8646.5	8646.5	8646.5	343	2752907
P08	10000	1	50	早期	98.9335	0.0101078	10107.1	10107.1	10107.1	232	2754156
P08	10000	1	50	当前	110.627	0.00903938	9038.37	9038.37	9038.37	246	2867997
P08	100000	1	50	初始	112.665	0.00887591	8875.18	8875.18	8875.18	2800	27434544
P08	100000	1	50	早期	66.1276	0.0151223	15121.7	15121.7	15121.7	236	27446815
P08	100000	1	50	当前	252.795	0.00395577	3955.11	3955.11	3955.11	256	28588725
P09	10000	1	50	初始	2618460	0.00381904	0	0	0	0	2745245
P09	10000	1	50	早期	2342170	0.00426955	0	0	0	0	2748835
P09	10000	1	50	当前	2565580	0.00389775	0	0	0	0	2876126
P09	100000	1	50	初始	2593240	0.0385617	0	0	0	0	27373994
P09	100000	1	50	早期	2329820	0.0429218	0	0	0	0	27409053
P09	100000	1	50	当前	2579180	0.038772	0	0	0	0	28684971
P10	10000	1	50	早期	1879170	0.00532151	0.055	0.057	0.059	0	2748913
P10	10000	1	50	当前	1973050	0.00506829	0.03	0.033	0.035	0	2876127
P10	100000	1	50	早期	1783440	0.0560714	0.055	0.057	0.058	0	27409054
P10	100000	1	50	当前	1879390	0.0532087	0.029	0.031	0.032	0	28684972
P11	10000	1	50	早期	64099.7	0.156007	0	0	0	5642424	5495135
P11	10000	1	50	当前	59731.2	0.167417	0	0	0	8613066	5753060
P11	10000	8	50	早期	54733.6	0.182703	0	0	0	7133964	5490245
P11	10000	8	50	当前	50914	0.19641	0	0	0	10634982	5751555
P11	100000	1	50	早期	60911.4	1.64173	0	0	0	56873416	54823571
P11	100000	1	50	当前	457052	0.218793	0	0	0	58573603	57365728
P11	100000	8	50	早期	45630.8	2.1915	0	0	0	98836739	54803332
P11	100000	8	50	当前	156497	0.63899	0	0	0	58620062	57360117
P12	10000	1	50	早期	64416.9	0.155239	0	0	0	5642424	5495135
P12	10000	1	50	当前	60463.1	0.16539	0	0	0	8617400	5753060
P12	10000	8	50	早期	55604.4	0.179842	0	0	0	6759223	5489978
P12	10000	8	50	当前	52084	0.191998	0	0	0	10626218	5751341
P12	100000	1	50	早期	62798.7	1.59239	0	0	0	56873340	54833273
P12	100000	1	50	当前	470293	0.212633	0	0	0	58569268	57365728
P12	100000	8	50	早期	45741.5	2.1862	0	0	0	100680276	54802623
P12	100000	8	50	当前	161767	0.618173	0	0	0	57813548	57360129
P13	10000	1	50	早期	11284700	0.155954	0.051	0.053	0.063	5642497	5495135
P13	10000	1	50	当前	22678000	0.167368	0.03	0.031	0.038	8643353	5753060
P13	10000	8	50	早期	7954740	0.182512	0.051	0.053	0.094	7843244	5490245
P13	10000	8	50	当前	22014500	0.19614	0.03	0.045	0.05	10636709	5751555
P13	100000	1	50	早期	8517080	1.64169	0.051	0.053	0.094	56873416	54823571
P13	100000	1	50	当前	22902100	0.218737	0.03	0.031	0.077	63437064	57365728
P13	100000	8	50	早期	7566200	2.19132	0.051	0.053	0.087	100582102	54803332
P13	100000	8	50	当前	19438400	0.638801	0.032	0.048	0.056	61856807	57360117
P14	10000	1	50	早期	280731	0.0356213	35620.6	35620.6	35620.6	229200	25223
P14	10000	1	50	当前	1898270	0.00526796	5267.27	5267.27	5267.27	30	16347
P14	100000	1	50	早期	279024	0.358392	358392	358392	358392	2294330	158817
P14	100000	1	50	当前	4321590	0.0231396	23139	23139	23139	129	76501
P15	10000	1	0	早期	793097	0.0126088	1.049	1.557	1.849	0	2830821
P15	10000	1	0	当前	1211630	0.00825336	0.604	1.023	1.217	0	3135774
P15	10000	1	50	早期	778664	0.0128425	1.118	1.502	1.778	0	2830822
P15	10000	1	50	当前	1341710	0.00745315	0.601	0.896	1.268	0	3135775
P15	10000	1	100	早期	881248	0.0113475	1.045	1.455	1.726	0	2830823
P15	10000	1	100	当前	1579950	0.00632931	0.558	0.838	1.115	0	3135776
P15	100000	1	0	早期	636067	0.157216	1.347	1.991	2.458	0	28229110
P15	100000	1	0	当前	946786	0.10562	0.857	1.254	1.68	0	31281177
P15	100000	1	50	早期	649716	0.153914	1.352	2.092	2.555	0	28228957
P15	100000	1	50	当前	1032970	0.0968086	0.834	1.168	1.436	0	31281178
P15	100000	1	100	早期	684616	0.146067	1.358	1.918	2.357	0	28228573
P15	100000	1	100	当前	1232870	0.0811113	0.74	1.063	1.394	0	31281179
P16	10000	1	50	早期	70044.7	0.142766	2.731	4.762	5.655	5769157	2836186
P16	10000	1	50	当前	506738	0.0197341	1.709	3.497	4.551	3030567	3039098
P16	100000	1	50	早期	63323.7	1.57919	3.486	5.274	6.8	58377195	28236577
P16	100000	1	50	当前	470104	0.212719	1.766	3.537	4.636	56906651	31266398
P17	10000	1	50	初始	110381	0.0905955	1.785	3.301	4.02	5639813	2748351
P17	10000	1	50	早期	69914.1	0.143033	2.538	4.093	5.036	5642345	2751730
P17	10000	1	50	当前	523944	0.019086	1.651	3.399	5.587	2950595	2959122
P17	100000	1	50	初始	101562	0.984625	1.782	3.474	4.974	56623206	27390700
P17	100000	1	50	早期	63997.4	1.56256	3.233	4.745	6.37	56648737	27425471
P17	100000	1	50	当前	482424	0.207286	1.685	3.475	4.634	52788442	28687105

C.3 峰值 RSS 场景编号

编号	场景
C01	`combined_concurrent`
C02	`combined_contract`
C03	`combined_gc`
C04	`combined_overwrites`
C05	`combined_reopen`
C06	`combined_views`
C07	`metadata_contract`
C08	`metadata_reopen`
C09	`perf_combined_gc`
C10	`perf_combined_stats_under_write`
C11	`perf_concurrent`
C12	`perf_read`
C13	`perf_reopen`
C14	`perf_scan`
C15	`perf_stats`
C16	`perf_stats_under_write`
C17	`perf_ttl_gc`
C18	`perf_ttl_mixed`
C19	`perf_ttl_write`
C20	`perf_write`
C21	`ttl_contract`
C22	`ttl_views`

C.4 峰值 RSS 中位数

表 15　各场景进程峰值 RSS 的三次运行中位数

场景	N	线程	过期%	实现	峰值 RSS（KiB）
C01	100000	8	50	早期	120284
C01	100000	8	50	当前	136948
C02	100000	8	50	早期	8644
C02	100000	8	50	当前	8652
C03	100000	8	50	早期	8660
C03	100000	8	50	当前	8660
C04	100000	8	50	早期	8684
C04	100000	8	50	当前	8684
C05	100000	8	50	早期	8692
C05	100000	8	50	当前	8696
C06	100000	8	50	早期	8700
C06	100000	8	50	当前	8704
C07	100000	8	50	早期	8712
C07	100000	8	50	当前	8712
C08	100000	8	50	早期	41560
C08	100000	8	50	当前	43932
C09	10000	1	0	早期	8856
C09	10000	1	0	当前	10060
C09	10000	1	50	早期	8768
C09	10000	1	50	当前	11072
C09	10000	1	100	早期	8780
C09	10000	1	100	当前	11080
C09	100000	1	0	早期	42768
C09	100000	1	0	当前	46032
C09	100000	1	50	早期	25504

场景	N	线程	过期%	实现	峰值 RSS（KiB）
C09	100000	1	50	当前	38564
C09	100000	1	100	早期	11580
C09	100000	1	100	当前	39464
C10	10000	1	0	早期	13688
C10	10000	1	0	当前	13392
C10	10000	1	50	早期	9548
C10	10000	1	50	当前	11488
C10	10000	1	100	早期	8920
C10	10000	1	100	当前	11596
C10	10000	8	0	早期	14240
C10	10000	8	0	当前	16368
C10	10000	8	50	早期	10064
C10	10000	8	50	当前	11956
C10	10000	8	100	早期	8996
C10	10000	8	100	当前	11792
C10	100000	1	0	早期	84244
C10	100000	1	0	当前	96052
C10	100000	1	50	早期	46208
C10	100000	1	50	当前	57088
C10	100000	1	100	早期	16876
C10	100000	1	100	当前	26992
C10	100000	8	0	早期	85004
C10	100000	8	0	当前	97252
C10	100000	8	50	早期	46752
C10	100000	8	50	当前	59148
C10	100000	8	100	早期	16248
C10	100000	8	100	当前	44704
C11	10000	1	50	初始	9200
C11	10000	1	50	早期	9184
C11	10000	1	50	当前	9184
C11	10000	8	50	初始	9220
C11	10000	8	50	早期	9216
C11	10000	8	50	当前	9220
C11	100000	1	50	初始	30700
C11	100000	1	50	早期	30748
C11	100000	1	50	当前	42768
C11	100000	8	50	初始	32492
C11	100000	8	50	早期	32604
C11	100000	8	50	当前	37652
C12	10000	1	50	初始	9316
C12	10000	1	50	早期	9304
C12	10000	1	50	当前	9312
C12	100000	1	50	初始	31692
C12	100000	1	50	早期	32840
C12	100000	1	50	当前	33680
C13	10000	1	50	初始	9392
C13	10000	1	50	早期	9388
C13	10000	1	50	当前	9660
C13	100000	1	50	初始	31440
C13	100000	1	50	早期	37732
C13	100000	1	50	当前	32740
C14	10000	1	50	初始	9456
C14	10000	1	50	早期	9444
C14	10000	1	50	当前	9456

场景	N	线程	过期%	实现	峰值 RSS（KiB）
C14	100000	1	50	初始	30700
C14	100000	1	50	早期	32088
C14	100000	1	50	当前	31676
C15	10000	1	50	早期	9508
C15	10000	1	50	当前	9508
C15	100000	1	50	早期	9612
C15	100000	1	50	当前	14960
C16	10000	1	50	早期	9544
C16	10000	1	50	当前	9548
C16	10000	8	50	早期	9564
C16	10000	8	50	当前	9572
C16	100000	1	50	早期	15272
C16	100000	1	50	当前	25524
C16	100000	8	50	早期	15416
C16	100000	8	50	当前	20016
C17	10000	1	50	早期	9664
C17	10000	1	50	当前	11248
C17	100000	1	50	早期	43540
C17	100000	1	50	当前	45952
C18	10000	1	0	早期	9688
C18	10000	1	0	当前	9688
C18	10000	1	50	早期	9708
C18	10000	1	50	当前	9708
C18	10000	1	100	早期	9720
C18	10000	1	100	当前	9724
C18	100000	1	0	早期	31604
C18	100000	1	0	当前	43852
C18	100000	1	50	早期	31268
C18	100000	1	50	当前	34772
C18	100000	1	100	早期	31720
C18	100000	1	100	当前	35084
C19	10000	1	50	早期	9804
C19	10000	1	50	当前	9804
C19	100000	1	50	早期	31360
C19	100000	1	50	当前	42992
C20	10000	1	50	初始	9844
C20	10000	1	50	早期	9840
C20	10000	1	50	当前	9844
C20	100000	1	50	初始	30540
C20	100000	1	50	早期	30732
C20	100000	1	50	当前	41404
C21	100000	8	50	早期	9892
C21	100000	8	50	当前	9896
C22	100000	8	50	早期	9896
C22	100000	8	50	当前	9896